

Tratamento de Dados na Prática

Do Caos à Análise com Python

Evento: Semana da Estatística (SEST 2026)

A Realidade do Mercado de Dados

Modelos estatísticos sofisticados não corrigem dados ruins. No dia a dia de um profissional da área, a estruturação e a qualidade da informação que alimenta os algoritmos são fundamentais para obter insights válidos.

"Estima-se que cerca de 80% do tempo em projetos de dados seja gasto em limpeza e preparação das bases."

1. O Diagnóstico (A Base Bruta)

Abaixo está o exemplo de uma base de dados típica antes de passar por qualquer processo de saneamento. Nota-se a presença de erros de preenchimento, anomalias drásticas e formatação mista.

ID Cliente	Idade	Gênero	Renda Mensal	Data Cadastro
2	34	F	3.200,50	15/02/2023
3	300	masc	4500	2023-03-10
4	45	Fem	1.500	NaN
6	vinte e um	Feminino	150k	2023-06-11

Análise Exploratória Inicial: Outliers impossíveis de idade (Idade: 300), números descritos por extenso ("vinte e um"), máscaras financeiras misturando os padrões pt-BR e internacional (1.500 vs 150k) e formatos de datas completamente inconsistentes.

2. Tratamento Avançado de Strings e Regras Lógicas

Utilizando a biblioteca **Pandas** combinada com **Expressões Regulares (Regex) Otimizadas**, aplicamos um tratamento para contornar cada anomalia de forma segura.

```
# 1. IDADE: Resgate de texto por extenso e limites lógicos
df["idade"] = df["idade"].replace({"vinte e um": 21})
df["idade_num"] = pd.to_numeric(df["idade"], errors="coerce")
df.loc[(df["idade_num"] < 18) | (df["idade_num"] > 100), "idade_num"] = np.nan
df["idade_final"] = df["idade_num"].astype("Int64") # Remove o decimal (.0) mantendo os

# 2. GÊNERO: Padronização imediata (Padrão UPPER de mercado)
df["genero_limpo"] = df["genero"].astype(str).str.strip().str.upper().str[0]

# 3. RENDA: Limpeza simplificada e inteligente com Regex
df["renda_limpa"] = (
    df["renda_mensal"]
    .astype(str)
    .str.lower()
    .str.replace("k", "000", regex=False) .str.replace(r"\.(?
    =\d{3}(\D|$))", "", regex=True) .str.replace(",", ".", # Remove ponto APENAS se for mil
    regex=False) # Vírgula vira decimal padrão
)
df["renda_limpa"] = pd.to_numeric(df["renda_limpa"], errors="coerce")
```

3. A Ordem (Resultado Final)

Após a execução do pipeline, os dados de idade perdem as casas decimais artificiais e a renda mantém a escala correta (evitando cálculos indevidos por eliminação de pontos decimais).

id	idade	genero	renda	data
2	34	F	3200.50	15/02/2023
3	NaN	M	4500.00	10/03/2023
4	45	F	1500.00	NaN
6	21	F	150000.00	11/06/2023

"Tratar dados não é uma etapa; é uma responsabilidade."

Realização: Gauss Jr. Consultoria Estatística

Ministrante: Lucas Sá

Monitores: Carlos Eduardo e Yuri Mariano (Monitores de Apoio)